

# CH2 Intro Apprentissage machine

couple image  
 Couple aléatoire  $Z = (X, Y) \in \mathcal{X} \times \mathcal{Y}$   
 obj : trouver 1 fct qui lie  $X$  à  $Y$  :  $P(Y|X)$  (proba conditionnelle)  
 existe ✓  
 peut exister pas

$\exists$  1 appli  $T: \mathcal{X} \rightarrow \mathcal{Y}$   $\uparrow$   $Y \sim T(X)$  où  $T$  déterminé  
 obj : trouver  $h \sim T$  peut avoir des erreurs (1 chat, 1 chien)  
 1 fct nous dit chat ou chien  
 risque moyen défini par  $E(h) = \int l(h(x), y) dP(X, Y)$  (chercher à minimiser)  
 err moy de classifcat qu'on fait (risque moy) (de prédic données)  
 où  $P(\cdot, \cdot)$  la loi jointe entre  $X$  et  $Y$ .  
 $l: \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R} \cup \{+\infty\}$   
 est 1 fct de perte. (pour mesurer la qualité d'une fct de prédic  $h$ )

On va chercher  $h^* = \underset{h: \mathcal{X} \rightarrow \mathcal{Y}}{\operatorname{argmin}} E(h)$  ( $\mathcal{P}$ )

Pour rendre ce pbl attaquable on va utiliser 2 ingrédients :

risque empirique et regularisation.  
 peut être calculé en discrétisant  $Z$ . On remplace  $E(h)$  par  $E_n(h)$  définie par  $E_n(h) = \sum_{i=1}^n l(h(x_i), y_i)$   
 où  $(x_i, y_i)$  sont tirés au hasard suivant la loi  $P$ .  
 (On discrétise l'ens : remplacer esp infini  $\rightarrow$  esp fini)  
 Consiste à choisir un espace de fct  $\mathcal{H}$  discret par 1 rbs fini de paramètres  
 On remplace ainsi : ( $\mathcal{P}$ ) par ( $\mathcal{P}_n$ ):  

$$\inf_{h \in \mathcal{H}} E_n(h) \quad (\mathcal{P}_n)$$

- Quel est l'effet de minimiser  $E_n$  plutôt que  $E$ ?
- de la régularisat° par  $\mathcal{H}$ ?
- Comment minimiser ( $\mathcal{P}_n$ ) numériquement?
- Quelle
- Quelle est la prédic° de minimisat° mé

## Exemple

1) Classification

En classifcat°,  $\mathcal{Y}$  discret e.g.  $\{0, 1, \dots, 9\}$   
 $\{\text{chat}, \text{chien}\}$

la fct perte est typiquement :


$$l(\hat{y}, y) = \begin{cases} 0 & \text{si } \hat{y} = y \\ 1 & \text{sinon} \end{cases}$$



$\hat{y}$ : val prédite  
 $(\hat{y} = h(x))$   
 $y$ : vrai val

- Fct "hinge"

$$l(\hat{y}, y) = \max(0, 1 - \hat{y}y)$$



- Divergence de Kullback-Leibler.

$$l(\hat{y}, y) = D(\hat{y} \| y) = \sum_{i=1}^I \hat{y}_i \log\left(\frac{\hat{y}_i}{y_i}\right) \quad I: \text{nbre de classes}$$

2) Regression :

En regression, l'espace  $\mathcal{Y}$  est continu (e.g.  $\mathbb{R}^n$ )

Par exemple, supposons que  $Y = A(X) + B$ , où  $A: \mathbb{R}^n \rightarrow \mathbb{R}^n$

$\swarrow$  image floue  
 $\searrow$  image net  
 $\downarrow$  bruit  
 $\hookrightarrow$  à trouver

$B \sim \mathcal{N}(0, \sigma^2 I_n)$

$$\min_{h: \mathbb{R}^n \rightarrow \mathbb{R}^n} \int \int \ell(h(A(x) + B), x) dP_X(x) dP_B(b)$$

$\swarrow$  vrai image       $\searrow$  l'hes image poss       $\downarrow$  réalisation du bruit poss

Dans ce cas, on prend typiquement :

- $\ell(\hat{y}, y) = \frac{1}{2} \|\hat{y} - y\|_2^2$  (risque quadratique)
- $\ell(\hat{y}, y) = \|\hat{y} - y\|_1$  (robuste)
- $\ell(\hat{y}, y) = NN(\hat{y}, y)$  où  $NN$  est un véc de neurones.

**Exemple de régularisation :** De façon générale, les fct de prédic<sup>t</sup> sont paramétrées par des poids  $w \in \mathbb{R}^d$ .

Une fct de la famille  $\mathcal{H}$  est définie par :  $h: \mathcal{X} \times W \rightarrow \mathcal{Y}$   
 $\downarrow$   
 esp d'entrée  
 $(x, w) \mapsto h(x, w)$

Avec  $\mathcal{H} = \{h(\cdot, w), w \in W\}$  où  $W$  est l'espace des poids admissibles :

- $\mathbb{R}^d$
- $\mathbb{R}_+^d$
- $[0, 1]^d$